

Onboarding y Base de Conocimiento

Plan para cerrar el circuito de contenido y poder vender la plataforma sin semanas de curación manual por cliente.

Intellix · Plataforma de conocimiento con IA Versión 1 · 22 de septiembre de 2026 Para: equipo (Alejo, Guille)

En una frase: hoy el bot responde bien lo que está en los documentos y, cuando algo no está, lo dice. Lo que falta no es motor: es que el *cliente* sepa qué le falta y pueda completarlo desde su panel, y que pueda subir sus archivos tal como los tiene. Eso es lo que vende.

1. Por qué: el diagnóstico con números

Todo lo que sigue sale de mediciones sobre el cliente real (MutuaLyF), no de suposiciones.

HALLAZGO	DATO	QUÉ SIGNIFICA
Todo el corpus del cliente fue convertido a mano	18 de 18 documentos son .txt	El pipeline acepta PDF, Word, HTML y JSON, pero la guía pide texto plano con plantilla. Ahí están las semanas por cliente.
El bot no sabe una parte relevante de lo que le preguntan	15 % de las respuestas son “no encontré esa información” (123 de 802, 90 días)	Es un backlog de contenido concreto y con nombre. Hoy nadie lo ve: nos enteramos leyendo conversaciones a mano.
Conversaciones que terminan en un humano	11 % (22 de 207)	Segunda señal de hueco, tampoco visible.
Los casos que investigamos a fondo eran de contenido, no del motor	4 de 4 (“qué planes hay”, “modalidades”, “descuento de haberes”, “alta por prestador”)	Ningún fragmento los respondía. Probamos dos mejoras de motor (reescritor, modelo de embeddings grande): cero cambio. El motor está bien; falta contenido y visibilidad.
Calidad del motor sobre el corpus real	30/30 casos de la suite	Datos duros, multi-turno, premisas falsas, trampas, nombres: todo pasa. No hay que reconstruir nada.
El motor de ingesta ya es sofisticado	6 tipos de documento, control de calidad por IA, duplicados, contradicciones, edición que sobrevive al reproceso	Hay que abrirle la puerta a más formatos y cerrarle el circuito, no rehacerlo.

2. Qué ve el cliente: la sección “Base de conocimiento”

Una sola feature, con nombre, en el panel del administrador del cliente. Cuatro pestañas que siguen el recorrido natural: **cargar** → **revisar** → **completar** → **probar**. Reusa los patrones que ya existen en el panel (lista con detalle, formularios laterales, la pantalla de Documentos).

- 1 Documentos — cargar.** Arrastra lo que tenga: Excel, CSV, PDF (con tablas o escaneado), Word, PowerPoint, Markdown, o un link a su sitio. Antes de confirmar ve una **vista previa**: cómo lo entendió el sistema (“una planilla de 120 filas”, “un documento de preguntas y respuestas”, “un reglamento”), cuántos fragmentos va a generar y advertencias en lenguaje claro (“la tabla de la página 3 puede perder sus encabezados”, “esta sección no tiene preguntas; el bot la va a entender peor”). Botón *Procesar*. Hoy se sube a ciegas y se descubre después.
- 2 Salud — revisar.** Un tablero simple, en filas: documentos, fragmentos, cuántos quedaron para revisar, duplicados, contradicciones, con semáforo. Casi todo existe hoy como piezas separadas; acá se junta en una vista. Sin números inventados: son los que el sistema ya calcula.
- 3 Preguntas sin respuesta — completar.** *La pestaña nueva, la que cierra el circuito.* Lo que la gente preguntó y el bot no supo, agrupado por tema y ordenado por frecuencia (“Planes / modalidades de afiliación — 4 veces — última: ayer”). Cada ítem tiene estado (pendiente, en curso, resuelto, descartado) y tres acciones: **ver la conversación** real donde falló; **documento relacionado** donde probablemente debería estar la respuesta; y **crear respuesta**, que abre un editor con un **borrador propuesto por la IA armado solo con los documentos del propio cliente**, indicando de dónde salió cada dato. El administrador lo edita, corrige o descarta, y **guarda**. Al guardar, se convierte en un documento suyo (origen “Panel”), entra por la ingesta normal, y el sistema **vuelve a hacer la pregunta original**: si ahora responde, el ítem pasa a resuelto con ✓; si no, queda en curso y avisa.
- 4 Probar — evaluar.** Botón *Evaluar mi base*: el sistema hace 20 preguntas típicas del rubro y devuelve un puntaje y la lista de las que no respondió, que caen directo en la pestaña 3. Es el informe del día uno para el cliente nuevo y el chequeo periódico para el existente.

Para el cliente es una sola cosa: “ahora la plataforma me dice qué le falta y me ayuda a completarlo”.

3. Principios que rigen el diseño

PRINCIPIO	QUÉ IMPLICA
El contenido es del cliente. Nosotros nunca cargamos, redactamos ni editamos en su base.	La IA <i>propone</i> a partir de lo que el cliente ya tiene; el administrador lee, edita y guarda con su clic. Aprobación siempre manual . Nada se publica solo.
Lo que el cliente escribe en el panel es tan suyo como lo que sube.	Ya perdimos ediciones manuales una vez (agosto). Por eso: la descarga trae siempre la versión vigente con las correcciones; las respuestas creadas en el panel tienen origen “Panel” visible, son exportables y están en el backup diario; borrar pide confirmación y va a una papelera de 30 días; botón <i>Exportar toda mi base</i> . El conocimiento no es rehén nuestro: también es argumento de venta.
Genérico, multitenant.	Nada específico de un rubro en código ni prompts. Las preguntas típicas para “Probar” salen de la descripción del negocio de cada tenant.
Sin modelos locales en el servidor.	La lectura de PDF complejo o escaneado se hace con el modelo con visión por API (el mismo que ya usamos). Rápido y son centavos.
Sin mejora medida no se avanza.	Cada pieza tiene criterio de aceptación. Lo que toque el motor corre la suite completa antes y después.

4. El plan por bloques

Esfuerzos estimados en días de desarrollo. El orden dentro de cada bloque es el propuesto; entre bloques, el 1 va primero porque es lo que cierra la venta.

Bloque 1 — Cerrar el circuito (lo que vende)

#	PIEZA	ESFUERZO	CRITERIO DE ACEPTACIÓN
1	Pestaña “Preguntas sin respuesta”: lista agrupada por tema, frecuencia, estado, ver conversación, documento relacionado. Se alimenta de la señal que ya se guarda en <code>consultas_log</code> (trust gate), de las respuestas “no encontré” y de las derivaciones. solo admin aviso por mail semanal, con interruptor por tenant	2–3 d	Con datos reales del tenant, un admin identifica en menos de un minuto qué le falta. Cero cambios en el motor.
2	Crear respuesta con borrador asistido: editor con propuesta de la IA a partir de los documentos del cliente, fuentes citadas, guardar → documento origen “Panel” → re-test automático de la pregunta original.	3–4 d	El re-test marca resuelto solo si el bot responde la pregunta original. La respuesta guardada aparece en la descarga y en el backup.
3	Evaluar mi base: 20 preguntas típicas generadas desde la descripción del tenant, puntaje, huecos a la pestaña 1.	3–4 d	Corre en menos de 2 minutos y no repite preguntas cacheadas (purga cache antes).
4	Propiedad del contenido: descarga = versión vigente siempre; origen “Panel” visible; exportar toda la base; papelera de 30 días con confirmación al borrar.	2–3 d	Un documento editado a mano y borrado se recupera íntegro desde la papelera; la exportación incluye lo del panel.

Bloque 2 — Formatos (la puerta de entrada)

Decisión tomada: **todos en la primera tanda.**

#	PIEZA	ESFUERZO	CRITERIO DE ACEPTACIÓN
5	Excel y CSV: una fila = un registro con sus encabezados repetidos (lo que la evidencia de 2026 muestra como mejor estrategia para planillas); se enchufa en la estrategia de listados que ya existe en el chunker (extracción automática de "Campo: valor").	3 d	Una nómina de 200 filas: "¿qué horario tiene X?" responde con la fila correcta en 5 de 5 pruebas.
6	PDF con tablas y PDF escaneado vía modelo con visión por API: cada página se convierte a texto estructurado que conserva las tablas; resuelve los dos casos con una sola herramienta, en la ingesta (asincrónica: que tarde 30–60 s por documento no afecta al bot).	5–7 d	El caso f_19 (dato numérico en tabla que pierde el encabezado) pasa. Un PDF escaneado entra con texto, no vacío.
7	PowerPoint y Markdown.	2 d	Un .pptx de capacitación genera fragmentos por diapositiva con su título.
8	Sitio web por URL: rastreo acotado al dominio, un fragmento por sección de página.	3–4 d	Un sitio institucional de 30 páginas queda cargado en menos de 5 minutos. Es el alta de demo.

Bloque 3 — Que el cliente sepa antes de subir

#	PIEZA	ESFUERZO	CRITERIO DE ACEPTACIÓN
9	Vista previa al subir: tipo detectado, cantidad de fragmentos, advertencias concretas (tablas que pierden encabezado, secciones sin pregunta, texto escaneado ilegible), antes de procesar.	5 d	Las advertencias corresponden a fallas reales conocidas del chunker; ninguna es genérica.
10	Guía nueva: de "reescribí todo a .txt con plantilla" a "subí lo que tengas; el sistema te dice qué mejorar".	1 d	Un cliente nuevo carga su material sin hablar con nosotros.

Bloque 4 — Motor (solo con medición)

#	PIEZA	ESFUERZO	CRITERIO
11	Clasificar las 123 preguntas sin respuesta reales: vocabulario (la respuesta estaba y no se encontró) vs. contenido (no estaba) vs. fuera de alcance. Solo lectura.	½ d	Un número por categoría. Decide el punto 12.
12	Indexación por preguntas (doc2query / HyPE): generar 3–5 preguntas en lenguaje de usuario por fragmento, con filtro de fidelidad, y usarlas para encontrar el fragmento. Solo si el punto 11 muestra que el vocabulario pesa , y coordinada con el reescritor para no tener dos mecanismos para lo mismo.	4–5 d	Los casos de vocabulario de la suite pasan sin escribir sus palabras en ningún lado; los 30 históricos no empeoran.

5. Decisiones tomadas

TEMA	DECISIÓN
Aprobación de borradores	Siempre manual: el administrador del cliente lee, edita y guarda. Nunca automático.
Quién ve "Preguntas sin respuesta"	Solo el administrador del cliente (no el operador, por ahora).
Aviso por mail de huecos nuevos	Sí, resumen semanal, con interruptor de encendido/apagado por tenant.
Contenido creado en el panel	Origen "Panel" visible, exportable, en el backup, papelera de 30 días.
Lectura de PDF complejo / escaneado	Modelo con visión por API. No modelos locales en el VPS.
Formatos	Todos en la primera tanda: Excel/CSV, PDF con visión, PowerPoint, Markdown, URL.
Lista inicial de la mutual	No se precarga con las 123 preguntas históricas (venían de un motor en construcción). Se define aparte cómo arranca.
Indexación por preguntas	Diferida: se decide con la clasificación del punto 11.

6. Lo que NO hacemos, y por qué

- **Agentes en el bot de consultas.** La evidencia de 2026 es consistente: multiplican el costo 3–10× y llevan la latencia de 1–2 s a 4–15 s; solo se justifican en preguntas de varios saltos o dominios de alto riesgo. Para "¿cuál es el horario de pediatría?" es pagar de más para responder peor. Descartado.
- **Parches de prompt por caso.** Seis arreglos al reescritor en agosto, cada uno por un caso. Probamos uno más para "planes" y lo descartamos: resolvía ese caso y dejaba el próximo. Solo cambios de arquitectura medidos contra toda la suite.
- **Cambiar el modelo de embeddings.** Probado en staging con el corpus re-vectorizado: los casos objetivo dieron idéntico. Descartado con medición.
- **Cargar contenido en la base del cliente.** Prohibido. Proponemos; ellos aprueban.
- **Construir la indexación por preguntas antes de medir cuánto arregla.** Los cuatro casos investigados eran de contenido. Primero el número.

7. Riesgos y cómo se contienen

RIESGO	CONTENCIÓN
El borrador de la IA propone algo que el cliente aprueba sin leer	Aprobación manual con las fuentes citadas al lado; el re-test automático muestra si la respuesta quedó bien; origen "Panel" visible para auditar después.
La lectura por visión de un PDF interpreta mal una tabla	La vista previa muestra el resultado antes de procesar; el control de calidad por IA que ya existe marca fragmentos dudosos; el cliente puede editar cualquier fragmento.
Costo de API en la ingesta	Centavos por documento; se hace una vez. Un PDF de 30 páginas por visión ≈ 30 llamadas. Se registra el consumo por tenant (ya existe <code>usage_events</code>).
Más complejidad en el motor	Los bloques 1–3 no tocan el motor de respuesta. El bloque 4 va detrás de flag y solo con medición.
Pérdida de trabajo del cliente	Bloque 1, pieza 4: versión vigente en la descarga, backup, papelera, exportación.

8. Calendario propuesto

CUÁNDO	QUÉ	PRODUCCIÓN
Semana del 22/09	Pruebas del cliente. Sin cambios. Clasificación de las 123 preguntas (solo lectura). Cerrar el aislamiento de red entre staging y producción.	No se toca
Semanas del 29/09 y 6/10	Bloque 1 completo (pestañas Preguntas sin respuesta, Crear respuesta, Evaluar, Propiedad del contenido) en <code>dev-local</code> ; medición en staging.	No se toca
Semanas del 13/10 y 20/10	Bloque 2 (formatos) y Bloque 3 (vista previa, guía).	Pasaje del Bloque 1 con OK de ambos
Semana del 27/10	Estabilización, suite completa, límites de consultas reactivados, token del widget renovado (vence 02/11), guardia definida.	Pasaje de Bloques 2–3 con OK de ambos
1 de noviembre	Go-live con onboarding vendible.	—
Noviembre	Bloque 4 según el número de la clasificación.	Solo con medición

Cómo sabremos que funcionó: el porcentaje de respuestas "no encontré" del cliente (hoy 15 %) baja mes a mes, y cada baja tiene un ítem "resuelto" en la pestaña de huecos que la explica. Un cliente nuevo carga su material sin hablar con nosotros, y el informe de *Evaluar mi base* le dice el día uno qué tiene y qué le falta.

Fuentes de las afirmaciones externas: Intercom Fin (huecos de contenido como backlog desde conversaciones no resueltas); "Structure-Aware Chunking for Tabular Data in RAG" (2026) para la estrategia fila-como-registro; comparativas de agentic RAG vs. RAG tradicional (2026) para costo y latencia; benchmarks de parsers de PDF (Docling, Marker, LlamaParse) para la decisión de lectura por visión. Las mediciones internas están en `docs/LIMITES_CONOCIDOS.md` y en la suite `tests/quality/regresion_mutualyf.yaml`.